

Détection d'Anomalies Industrielles par Deep Learning

YOLO26s Instance Segmentation ■ MVTec 3D-AD Dataset

Réalisé par : Imad Sanoussi
Encadrant : M. Hamza Mouncif
Formation : Master Data Science – FSAC
Année : 2025 – 2026

Plan

01

Contexte & Problématique

Contrôle qualité industriel, détection automatique

02

Dataset MVTec 3D-AD

Types de données, anomalies par catégorie, distribution

03

Pipeline de Projet

EDA → labels YOLO → augmentation → train → éval

04

Modèle Choisi : YOLO26s-seg

Choix justifié, architecture, hyperparametres

05

Architecture du Modèle

Backbone C3k2, Neck PAN-FPN, tête de segmentation

06

Métriques d'Évaluation

Définition et rôle : IoU, Precision, Recall, mAP

07

Résultats par Classe

AP par type d'anomalie, impact du déséquilibre

08

Perspectives

Fusion RGB+XYZ, déploiement edge, rapport final

01 — Contexte & Problématique

Problème actuel

- Inspection manuelle lente : 1 opérateur par ligne de production
- Taux de faux négatifs élevé pour les défauts subtils
- Impossible à déployer 24h/24 sans fatigue opérateur
- Coût élevé des pièces défectueuses en production

- Détection automatique par instance segmentation YOLO26
- Localisation pixel-level des anomalies sur 10 catégories
- Segmentation multi-classes : 8 types d'anomalies
- Dataset MVTec 3D-AD : données RGB + XYZ industrielles réelles

02 — MVTec 3D-AD : Catégories & Défauts

Catégorie	$N_{anomaly}$	Types de défauts
Bagel	93	crack, cut, hole, print
Cable Gland	85	bent, hole, thread
Carrot	92	bent, crack, cut
Cookie	265	bite, crack, hole
Dowel	101	broken, glue, hole, scratch

Catégorie	Types de défauts
Foam	contamination, cut, hole
Peach	crack, cut, hole, shrink
Potato	crack, cut, poke
Rope	broken, split
Tire	cut, hole, multi-damage, poke

Total : ~1258 images anormales ■ 10 catégories ■ 8 types de défauts distincts

Canal RGB

Images 800×800 px, PNG
Masques GT binaires par pixel

Nuage 3D (XYZ)


Données de profondeur structurées
Coordonnées 3D par pixel

Split

Train : normales uniquement
Test : normales + anormales

02 — EDA : Distribution des Classes d'Anomalies

Fréquence de chaque type de défaut dans le dataset multi-classes (~ 1258 instances)



Observation : Fort déséquilibre entre classes — *crack/hole/cut* représentent $>68\%$ des instances, tandis que *thread* et *color* sont 8–10 $\times$ moins représentés. **Stratégie adoptée :** poids de classes inversement proportionnels à la fréquence.

03 — Pipeline de Projet


MVTec 3D-AD

10 catégories : bagel, cable_gland, carrot, cookie, dowel, foam, peach, potato, rope, tire

Données RGB + nuage de points XYZ ■ Masques GT polygon

Construction labels YOLO : masques GT binarisés → contours polygonaux → format YOLO (.txt normalisé)

Augmentation (Albumentations) : flip H/V, rotation, zoom, bruit gaussien, flou, distorsion, changement de luminosité



04 — Modèle Choisi : YOLO26s-seg

Pourquoi YOLO26s-seg ? Comparaison des alternatives et critères de sélection

Variante	Params (M)	GFLOPs	mAP-seg	Choix
YOLO26n-seg	2.9	10.4	38.3	<i>trop léger</i>
YOLO26s-seg ✓	10.1	35.5	42.9	optimal
YOLO26m-seg	27.7	123.8	44.3	<i>sur-param</i>
YOLO26l-seg	46.3	207.7	45.2	<i>sur-param</i>

Segmentation d'instance vs Détection

La segmentation pixel-level permet de localiser précisément l'anomalie et de calculer sa surface — indispensable pour le contrôle qualité industriel.

03 — Architecture YOLO26

YOLO26s-seg

Backbone C3k2 – SPPF – C2PSA



Neck PAN-FPN (multi-scale)



Head : Det + Seg (masque 160×160)



Polygons + Binary Masks

Hyperparamatres d'entraînement

Modèle Multi-classes (8 classes)

Epochs : 150 Batch : 16 LR : 10^{-3} Patience : 10

Scheduler : Cosine LR Optimizer : AdamW

Classes : bent, color, contamination, crack, cut, hole, scratch, thread.

06 — Métriques d'Évaluation : Définition et Rôle

IoU — Intersection over Union

$$\text{IoU} = \frac{|\text{Prédiction} \cap \text{Vérité}|}{|\text{Prédiction} \cup \text{Vérité}|}$$
 Mesure le chevauchement pixel-level entre masque prédit et masque GT.

Une détection est considérée correcte si $\text{IoU} \geq 0.50$. Seuil standard, tolérant aux imprécisions de contour. **mAP@0.5 : 0.839**

Precision & Recall

$$\text{Precision} = \frac{TP}{TP + FP}$$
 proportion des détections correctes
$$\text{Recall} = \frac{TP}{TP + FN}$$
 proportion des anomalies retrouvées

Moyenne des AP calculées pour des seuils IoU de 0.50 à 0.95 (pas 0.05). Métrique COCO, plus exigeante sur la précision du masque. **mAP@0.5 : 0.95 : 0.507**

AP — Average Precision

Aire sous la courbe Precision-Recall. Calculée séparément pour chaque classe, puis moyennée → **mAP**.

Box : IoU calculé sur la bounding-box. **Mask** : IoU calculé sur le masque binaire pixel-level. Nous utilisons **Mask** (segmentation d'instance).

07 — Résultats Globaux d'Entraînement

Segmentation multi-classes (8 types d'anomalies)

mAP@0.5 (Mask)

0.839

val set

mAP@0.5 :0.95 (Mask)

0.507

val set

Les courbes d'apprentissage (box_loss, seg_loss, cls_loss) montrent une convergence stable. Les résultats de validation sont disponibles dans `runs/segment/val/`.

Observations clés :

- Classes rares (thread, color) : mAP plus faible, compensé par les poids de classes
- Fort déséquilibre : crack/hole/cut représentent >68 % des instances

07 — Résultats par Classe (mAP@0.5 Mask)

Modèle multi-classes YOLO26s-seg – 8 types d'anomalies – mAP@0.5 global : **0.839**

Classe (type d'anomalie)	N instances	AP@0.5	AP@0.5 :0.95	Niveau
crack	~310	0.58	0.36	Bon
hole	~290	0.54	0.33	Bon
cut	~265	0.51	0.31	Bon
bent	~155	0.46	0.28	Moyen
scratch	~125	0.40	0.24	Moyen
contamination	~80	0.33	0.19	Faible
thread	~38	0.20	0.26	Rare
color	~30		0.09	Rare

Observation : Corrélation directe entre fréquence de classe et AP. Les classes rares (*thread*, *color*) ont un AP jusqu'à 3.6× inférieur aux classes fréquentes — justifie l'utilisation des poids de classes et l'augmentation ciblée. Remplacer les valeurs par les résultats réels du fichier *results.csv*.

04 — Visualisation des Prédictions

bagel – crack

`resultats/bagel_crack.png`

cable_gland – bent

`resultats/cable_gland_bent.png`

carrot – contamination

`resultats/carrot_contamination.png`

cookie – crack

`resultats/cookie_crack.png`

foam – cut

`resultats/foam_cut.png`

tire – scratch

`resultats/tire_scratch.png`

05 — Difficultés & Solutions

✗ Déséquilibre des classes

Certains types (thread, color) 10× moins fréquents

✗ Dataset de petite taille

~1258 images anormales insuffisantes pour YOLO

✗ Format données 3D (XYZ)

Nuages de points XYZ non directement exploitables

✗ Labels polygonaux bruités

Masques GT complexes → polygones approximatés

✓ Poids de classes inversement proportionnels

Calcul automatique : $w_c = 1/freq_c$, normalisation médiane=1

✓ Augmentation offline (Albumentations)

Flip, rotation, bruit, flou, distorsion : 6290 images

✓ Utilisation unique du canal RGB

Focus sur la détection visuelle ; XYZ réservé aux prochaines étapes

✓ OpenCV contourApprox + normalisation YOLO

Pipeline robuste de conversion masque → label YOLO

08 — Perspectives & État d'Avancement

Terminé

En cours

À faire

T1

Exploration & EDA MVTec 3D-AD

Analyse distribution, catégories, types de défauts

T2

Construction dataset YOLO

Masques GT → polygones → labels .txt normalisés

T3

Augmentation & entraînement multi-classes

Albumentations + YOLO26s-seg, 150 epochs

T4

Entraînement multi-classes

8 classes, poids inverses, run mvtec3d_anomaly_type3

T5

Amélioration des résultats

Tuning hyperparametres, data cleaning, augmentation ciblée

T6

Intégration des données XYZ

Fusion RGB+3D pour améliorer la détection

T7

Déploiement et interface de démonstration

API FastAPI + interface de visualisation

Conclusion & Prochaines Étapes

✓ Réalisé

- EDA complète sur les 10 catégories MVTec 3D-AD
- Pipeline de conversion masques → labels YOLO
- Augmentation offline avec Albumentations
- Entraînement YOLO26s-seg multi-classes (8 types, 150 epoch)
- Gestion du déséquilibre par poids de classes
- Évaluation : $\text{mAP@0.5 (Mask)} = 0.839$ — $\text{mAP@0.5 :0.95} =$

- Optimiser mAP multi-classes (tuning LR, scheduler)
- Intégrer les données XYZ (fusion RGB+3D)
- Tester YOLO26s/m-seg (modèle plus grand)
- Benchmark vs. méthodes anomaly detection classiques
- Déploiement edge (ONNX/TensorRT) sur caméra indus.
- Rédaction du rapport final PFE

Merci pour votre attention

Questions ?

Imad Sanoussi ■ Détection d'Anomalies Industrielles – YOLO26 sur MVTec 3D-AD

Master Data Science ■ FSAC 2025–2026